PROGRAMACIÓN PARA CIENCIA DE DATOS

Clase 4

Limpieza de Datos con R

Tema: Diagnóstico, Limpieza y Transformación de Datos en Datasets Reales

Lenguajes: R

Dataset: superstore_dirty.csv (Versión modificada para aprendizaje práctico)

Objetivos específicos:

- Identificar e interpretar valores faltantes (NA) y registros duplicados utilizando el ecosistema tidyverse.
- Estandarizar cadenas de texto mediante el paquete stringr (eliminación de espacios en blanco con str_trim() y unificación de formato).
- Convertir tipos de datos de texto a numéricos (parse_number() / as.numeric()) y a fechas con el paquete lubridate (ymd(), mdy()).
- Generar variables derivadas mediante mutate() para responder preguntas estratégicas de negocio.
- Exportar dataset limpio

Docente: M.Sc. Dolores Ivetthe Rodríguez López

Octubre 2026

Tabla de Equivalencias Principales: Python (Pandas) vs. R (tidyverse)

Utilice este cuadro de referencia para ayudar a estudiantes con conocimientos previos en Python a realizar la transición conceptual hacia R:

Operación de Limpieza	Python (Pandas)	R (tidyverse / dplyr / stringr)
Carga de datos CSV	pd.read_csv('file.csv', encoding='latin-1')	read_csv('file.csv', locale=locale(encoding='latin1'))
Conteo de Nulos	df.isnull().sum()	colSums(is.na(df))
Conteo Duplicados	df.duplicated().sum()	sum(duplicated(df))
Eliminar Duplicados	df.drop_duplicates()	df %>% distinct()
Imputar Nulos	df['col'].fillna(val)	df %>% mutate(col = replace_na(col, val))
Limpieza de Espacios	df['col'].str.strip()	df %>% mutate(col = str_trim(col))
Cambio de Caja Texto	df['col'].str.title()	df %>% mutate(col = str_to_title(col))
Reemplazo de Regex	df['col'].str.replace('$', '', regex=False)	df %>% mutate(col = str_replace_all(col, '\\$', ''))
Conversión a Fechas	pd.to_datetime(df['col'])	df %>% mutate(col = parse_date_time(col, ...))
Agrupación e Resumen	df.groupby('cat').agg(...)	df %>% group_by(cat) %>% summarise(...)

Mini reto final

Desarrollar en R el analizar del desempeño por categoría

> A partir del dataset ventas ya limpio, crear un reporte que muestre el desempeño de cada categoría (Category).

El reporte debe contener:

1. Ventas totales por categoría.
2. Ganancia total por categoría.
3. Cantidad de pedidos únicos.
4. Promedio de días de entrega.
5. Margen de ganancia (%).
6. Ordenar el resultado de mayor a menor según las ventas totales.

Deben utilizar:

group_by(),summarise(),sum(), mean(), n_distinct(),arrange()

Y recordar: na.rm = TRUE para ignorar valores faltantes.