



PROGRAMACIÓN PARA CIENCIA DE DATOS

Clase 4

Limpieza de Datos con R

Tema: Diagnóstico, Limpieza y Transformación de Datos en Datasets Reales

Lenguajes: R

Dataset: superstore_dirty.csv (Versión modificada para aprendizaje práctico)

Objetivos específicos:

- Identificar e interpretar valores faltantes (NA) y registros duplicados utilizando el ecosistema tidyverse.
- Estandarizar cadenas de texto mediante el paquete stringr (eliminación de espacios en blanco con `str_trim()` y unificación de formato).
- Convertir tipos de datos de texto a numéricos (`parse_number()` / `as.numeric()`) y a fechas con el paquete lubridate (`ymd()`, `mdy()`).
- Generar variables derivadas mediante `mutate()` para responder preguntas estratégicas de negocio.
- Exportar dataset limpio

Docente: M.Sc. Dolores Ivetthe Rodríguez López

Agosto 2026



Tabla de Equivalencias Principales: Python (Pandas) vs. R (tidyverse)

Utilice este cuadro de referencia para ayudar a estudiantes con conocimientos previos en Python a realizar la transición conceptual hacia R:

Operación de Limpieza	Python (Pandas)	R (tidyverse / dplyr / stringr)
Carga de datos CSV	<code>pd.read_csv('file.csv', encoding='latin-1')</code>	<code>read_csv('file.csv', locale=locale(encoding='latin1'))</code>
Conteo de Nulos	<code>df.isnull().sum()</code>	<code>colSums(is.na(df))</code>
Conteo Duplicados	<code>df.duplicated().sum()</code>	<code>sum(duplicated(df))</code>
Eliminar Duplicados	<code>df.drop_duplicates()</code>	<code>df %>% distinct()</code>
Imputar Nulos	<code>df['col'].fillna(val)</code>	<code>df %>% mutate(col = replace_na(col, val))</code>
Limpieza de Espacios	<code>df['col'].str.strip()</code>	<code>df %>% mutate(col = str_trim(col))</code>
Cambio de Caja Texto	<code>df['col'].str.title()</code>	<code>df %>% mutate(col = str_to_title(col))</code>
Reemplazo de Regex	<code>df['col'].str.replace('\$', "", regex=False)</code>	<code>df %>% mutate(col = str_replace_all(col, '\\\$', ""))</code>
Conversión a Fechas	<code>pd.to_datetime(df['col'])</code>	<code>df %>% mutate(col = parse_date_time(col, ...))</code>
Agrupación e Resumen	<code>df.groupby('cat').agg(...)</code>	<code>df %>% group_by(cat) %>% summarise(...)</code>



Mini reto final

Desarrollar en R el analizar del desempeño por categoría

A partir del dataset ventas ya limpio, crear un reporte que muestre el desempeño de cada categoría (Category).

El reporte debe contener:

1. Ventas totales por categoría.
2. Ganancia total por categoría.
3. Cantidad de pedidos únicos.
4. Promedio de días de entrega.
5. Margen de ganancia (%).
6. Ordenar el resultado de mayor a menor según las ventas totales.

Deben utilizar:

`group_by()`, `summarise()`, `sum()`, `mean()`, `n_distinct()`, `arrange()`

Y recordar: `na.rm = TRUE` para ignorar valores faltantes.